Taller VI: Introduccion al Aprendizaje Automatico

Reinaldo Kevin Díaz Parra C.I V-27979417

September 27, 2026

1 Introducción

En el ámbito del aprendizaje supervisado y el cálculo científico, uno de los desafíos fundamentales consiste en la reconstrucción o aproximación de una función continua subyacente $f : \mathbb{R}^d \to \mathbb{R}$ a partir de un conjunto discreto y finito de observaciones ruidosas $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, donde $\mathbf{x}_i \in \mathbb{R}^d$ representa el vector de características y $y_i = f(\mathbf{x}_i) + \eta_i$ corresponde a la respuesta observada sujeta a perturbaciones estocásticas η_i.

Tradicionalmente, las técnicas de aproximación global basadas en polinomios algebraicos sufren severas limitaciones cuando se extienden a dimensiones superiores o cuando los datos se encuentran irregularmente distribuidos en el dominio. Entre estas limitaciones destacan el fenómeno de Runge y la explosión dimensional, conocida como la *maldición de la dimensionalidad*. Frente a estos esquemas, las Redes de Funciones de Base Radial (RBF, por sus siglas en inglés: *Radial Basis Functions*) constituyen una alternativa robusta y flexible. Las RBF fundamentan su capacidad predictiva en una combinación lineal de núcleos simétricos locales $\phi(r)$ dependientes únicamente de la distancia euclídea euclidiana entre el punto de consulta y los centros de referencia del conjunto de datos:

$$s(\mathbf{x}) = \sum_{j=1}^{n} w_j \phi(\|\mathbf{x} - \mathbf{x}_j\|_2) \tag{1}$$

El comportamiento y la generalización de este modelo quedan determinados por el parámetro de forma (ϵ), el cual modula la escala espacial o ancho característico del núcleo. En el caso del núcleo gaussiano $\phi(r) = \exp(-(\epsilon r)^2)$, la selección de ϵ establece un compromiso crítico entre el alcance de la influencia vecinal y la estabilidad numérica: valores reducidos de ϵ incrementan el solapamiento entre funciones base —favoreciendo el filtrado de ruido pero aproximando la matriz del sistema a una condición singular—, mientras que valores elevados aíslan excesivamente las respuestas locales en torno a cada muestra conocida.

Asimismo, en escenarios reales donde las etiquetas incorporan ruido de medición, imponer una condición de interpolación exacta conduce inexorablemente al sobreajuste (*overfitting*) y al mal condicionamiento del sistema lineal subyacente $\mathbf{\Phi w} = \mathbf{y}$. Para mitigar esta inestabilidad, se recurre a la regularización de Tikhonov, la cual penaliza la magnitud de los coeficientes $\mathbf{w}$ e introduce una modificación de la forma $(\mathbf{\Phi} + \lambda \mathbf{I})\mathbf{w} = \mathbf{y}$, permitiendo suavizar la variedad estimada y aislar el ruido estadístico de la tendencia determinista.

El presente informe tiene por objetivo estudiar la aproximación de una superficie bidimensional no lineal utilizando RBF gaussianas regularizadas. Se presenta la formulación analítica del sistema lineal, la implementación numérica del algoritmo en el lenguaje Python y un análisis comparativo del efecto del parámetro de forma sobre la geometría de interpolación y el condicionamiento matricial.

2 Marco Teórico

2.1 Funciones de Base Radial (RBF)

Las Funciones de Base Radial constituyen un paradigma de aproximación no paramétrico donde la respuesta de una función aproximante $s : \mathbb{R}^d \to \mathbb{R}$ se construye a partir de la superposición ponderada de núcleos continuos cuya evaluación depende únicamente de la distancia euclídea euclidiana respecto

a un conjunto de puntos de referencia o centros $\{\mathbf{x}_j\}_{j=1}^n \subset \mathbb{R}^d$:

$$s(\mathbf{x}) = \sum_{j=1}^{n} w_j \phi\left(\|\mathbf{x} - \mathbf{x}_j\|_2\right) \tag{2}$$

donde $w_j \in \mathbb{R}$ representa el coeficiente de ponderación asociado al j-ésimo centro y $\phi : [0, \infty) \to \mathbb{R}$ es una función radial univariada continua.

En el presente estudio se adopta como núcleo la función gaussiana definida como:

$$\phi(r) = \exp\left(-(\epsilon r)^2\right) \tag{3}$$

donde $r = \|\mathbf{x} - \mathbf{x}_j\|_2$ denota la métrica euclídea y $\epsilon > 0$ corresponde al denominado *parámetro de forma* (*shape parameter*). Desde el punto de vista geométrico, ϵ gobierna la escala de decaimiento del núcleo:

- Para valores pequeños de ϵ, el ancho característico de la campana ($\sigma \sim 1/\epsilon$) diverge, confiriendo a cada núcleo una influencia global de largo alcance sobre el dominio.
- Para valores elevados de ϵ, σ decrece rápidamente hacia cero, limitando la influencia del núcleo estrictamente a un entorno vecinal hiperlocal en torno a $\mathbf{x}_j$.

2.2 Derivación del Sistema Lineal de Interpolación

Consideremos un conjunto de datos de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, donde $\mathbf{x}_i \in \mathbb{R}^d$ y $y_i \in \mathbb{R}$. En el esquema de interpolación estricta, se impone que la función aproximante $s(\mathbf{x})$ coincida exactamente con las observaciones en cada punto muestral:

$$s(\mathbf{x}_i) = y_i, \quad \forall i = 1, \ldots, n \tag{4}$$

Sustituyendo la expresión (2) en (4), se obtiene el sistema acoplado de n ecuaciones lineales con n incógnitas:

$$\sum_{j=1}^{n} w_j \phi\left(\|\mathbf{x}_i - \mathbf{x}_j\|_2\right) = y_i, \quad i = 1, \ldots, n \tag{5}$$

El sistema puede expresarse de forma matricial compacta como:

$$\mathbf{\Phi}\mathbf{w} = \mathbf{y} \tag{6}$$

donde:

$$\mathbf{\Phi} = \begin{bmatrix} \phi(\|\mathbf{x}_1 - \mathbf{x}_1\|) & \phi(\|\mathbf{x}_1 - \mathbf{x}_2\|) & \ldots & \phi(\|\mathbf{x}_1 - \mathbf{x}_n\|) \\ \phi(\|\mathbf{x}_2 - \mathbf{x}_1\|) & \phi(\|\mathbf{x}_2 - \mathbf{x}_2\|) & \ldots & \phi(\|\mathbf{x}_2 - \mathbf{x}_n\|) \\ \vdots & \vdots & \ddots & \vdots \\ \phi(\|\mathbf{x}_n - \mathbf{x}_1\|) & \phi(\|\mathbf{x}_n - \mathbf{x}_2\|) & \ldots & \phi(\|\mathbf{x}_n - \mathbf{x}_n\|) \end{bmatrix} \in \mathbb{R}^{n \times n} \tag{7}$$

junto con los vectores columna $\mathbf{w} = [w_1, w_2, \ldots, w_n]^T \in \mathbb{R}^n$ e $\mathbf{y} = [y_1, y_2, \ldots, y_n]^T \in \mathbb{R}^n$. Por simetría de la distancia métrica $\|\mathbf{x}_i - \mathbf{x}_j\| = \|\mathbf{x}_j - \mathbf{x}_i\|$, la matriz de colocación $\mathbf{\Phi}$ es simétrica ($\mathbf{\Phi} = \mathbf{\Phi}^T$). Asimismo, en virtud del teorema de Bochner-Micchelli, los núcleos gaussianos son estrictamente definidos positivos para centros distintos dos a dos, lo que garantiza formalmente la existencia y unicidad de la solución analítica $\mathbf{w} = \mathbf{\Phi}^{-1}\mathbf{y}$.

2.3 Inestabilidad Numérica y el Límite Plano ($\epsilon \to 0$)

A pesar de la invertibilidad analítica de $\mathbf{\Phi}$, en el cálculo de precisión finita la resolución de (6) presenta serios compromisos de estabilidad numérico-algebraica. El número de condición de la matriz, definido por:

$$\kappa(\mathbf{\Phi}) = \|\mathbf{\Phi}\|_2 \|\mathbf{\Phi}^{-1}\|_2 = \frac{\sigma_{\max}(\mathbf{\Phi})}{\sigma_{\min}(\mathbf{\Phi})} \tag{8}$$

crece de manera exponencial a medida que $\epsilon \to 0$ (límite plano) o cuando la distancia relativa entre centros se reduce.

Físicamente, a medida que ϵ disminuye, las funciones de base se aplanan progresivamente, de tal modo que $\phi(\|\mathbf{x}_i - \mathbf{x}_j\|) \to 1$ para todo par (i, j). En consecuencia, las columnas de la matriz $\mathbf{\Phi}$ devienen casi linealmente dependientes, provocando que los valores singulares mínimos $\sigma_{\min}(\mathbf{\Phi}) \to 0$.

Al resolver el sistema algebraico bajo esta condición, los errores de redondeo de punto flotante se amplifican catastróficamente. Esto induce vectores de coeficientes $\mathbf{w}$ con normas anómalamente grandes y alternancia de signos de gran magnitud ($w_j \gg 0$, $w_{j+1} \ll 0$), originando oscilaciones espurias de alta frecuencia entre los puntos de entrenamiento y comprometiendo por completo la capacidad de generalización del interpolador.

2.4 Regularización de Tikhonov

Cuando los datos observados incorporan ruido de medición $\eta_i \sim \mathcal{N}(0, \sigma_\eta^2)$, exigir la interpolación exacta (4) fuerza a la variedad aproximante a oscilar espuriamente para ajustar las perturbaciones estocásticas (*overfitting*).

Para restaurar el condicionamiento y obtener una reconstrucción regular, se reformula el problema de colocación como un problema variacional de mínimos cuadrados penalizados de Tikhonov (L_2 regularization):

$$\min_{\mathbf{w}} \mathcal{J}(\mathbf{w}) = \frac{1}{2}\|\mathbf{\Phi}\mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2}\|\mathbf{w}\|_2^2 \tag{9}$$

donde $\lambda > 0$ es el hiperparámetro de penalización. Calculando el gradiente respecto a $\mathbf{w}$ e igualando a cero:

$$\nabla_{\mathbf{w}} \mathcal{J}(\mathbf{w}) = \mathbf{\Phi}^T(\mathbf{\Phi}\mathbf{w} - \mathbf{y}) + \lambda\mathbf{w} = \mathbf{0} \tag{10}$$

Aprovechando la simetría y regularidad de $\mathbf{\Phi}$ ($\mathbf{\Phi}^T = \mathbf{\Phi}$), y considerando la forma de colocación lineal directa con penalización en la diagonal:

$$(\mathbf{\Phi} + \lambda\mathbf{I})\mathbf{w} = \mathbf{y} \tag{11}$$

donde $\mathbf{I} \in \mathbb{R}^{n\times n}$ denota la matriz identidad.

Desde una perspectiva espectral, la adición del término $\lambda\mathbf{I}$ traslada rígidamente todo el espectro de autovalores de $\mathbf{\Phi}$ en una magnitud λ:

$$\mu_k(\mathbf{\Phi} + \lambda\mathbf{I}) = \mu_k(\mathbf{\Phi}) + \lambda \tag{12}$$

Esto impone una cota inferior estricta al menor autovalor ($\mu_{\min} \geq \lambda$), limitando el número de condición a $\kappa \leq (\mu_{\max}+\lambda)/\lambda$ y previniendo que los coeficientes w_j diverjan ante perturbaciones de alta frecuencia. En consecuencia, la regularización relaja la necesidad de interpolar exactamente cada observación ruidosa, favoreciendo una solución de curvatura suave que extrae la tendencia subyacente del sistema.

3 Metodología Computacional y Desarrollo Experimental

La implementación del algoritmo de aproximación mediante Redes de Base Radial (RBF) se estructuró de manera modular en el lenguaje de programación Python, apoyándose en las librerías científicas `NumPy` para el álgebra lineal tensorial y `Matplotlib` para la proyección gráfica tridimensional.

3.1 Generación del Conjunto de Datos Sintéticos

Siguiendo las pautas del diseño experimental, se fijó una semilla de reproducibilidad pseudoaleatoria (`seed = 42`) para permitir la replicación exacta de las simulaciones numéricas. Se generó un conjunto de $n = 100$ puntos uniformemente distribuidos en el dominio bidimensional $\Omega = [-2, 2] \times [-2, 2]$:

$$\mathbf{x}_i = (x_i, y_i) \sim \mathcal{U}(-2, 2) \times \mathcal{U}(-2, 2), \quad i = 1, \ldots, 100 \tag{13}$$

El valor de respuesta determinista se construyó mediante la función bidimensional altamente no lineal $f(x, y) = \sin(x)\cos(y)$. A cada valor determinista se le superpuso una perturbación estocástica gaussiana centrada en cero, modelada según $\eta_i \sim \mathcal{N}(0, \sigma^2)$ con desviación estándar $\sigma = 0.05$, obteniéndose así el vector de entrenamiento perturbado:

$$z_i = \sin(x_i)\cos(y_i) + \eta_i, \quad i = 1, \ldots, 100 \tag{14}$$

3.2 Ensamblaje Matricial y Estabilización Numérica

Se definió computacionalmente el núcleo radial gaussiano mediante la función vectorial $\phi(r;\epsilon) = \exp(-(\epsilon r)^2)$, donde $r = \|\mathbf{x}_i - \mathbf{x}_j\|_2$ se calcula mediante la norma euclídea estándar. A partir del conjunto de entrenamiento de n centros, se construyó la matriz cuadrada de colocación $\mathbf{\Phi} \in \mathbb{R}^{n\times n}$.

Para resolver el sistema de coeficientes bajo presencia de ruido sin inducir singularidad numérica, se aplicó la corrección de Tikhonov sobre la diagonal principal de $\mathbf{\Phi}$:

$$\mathbf{A}_{\text{reg}} = \mathbf{\Phi} + \lambda \mathbf{I}_n \tag{15}$$

donde $\lambda = 10^{-6}$ corresponde al parámetro de amortiguamiento y $\mathbf{I}_n$ es la matriz identidad de orden n. La obtención del vector de pesos $\mathbf{w}$ se llevó a cabo resolviendo el sistema regularizado $\mathbf{A}_{\text{reg}}\mathbf{w} = \mathbf{y}$. Finalmente, para evaluar la respuesta continua del modelo, se discretizó el plano mediante una grilla uniforme de 50×50 puntos de evaluación.

3.3 Protocolo de Experimentación y Variación de ϵ

Con el propósito de caracterizar la influencia del parámetro de forma sobre la capacidad de generalización y la respuesta del modelo, se mantuvieron fijos el conjunto de datos de entrenamiento y el factor de regularización ($\lambda = 10^{-6}$), ejecutándose tres pruebas comparativas bajo distintos regímenes de escala espacial: $\epsilon = 0.2$ (núcleo ancho y sobre-suavizado), $\epsilon = 1.5$ (núcleo intermedio) y $\epsilon = 10.0$ (núcleo estrecho con localización extrema).

3.4 Implementación en Python (Código Fuente)

A continuación, se presenta el código fuente desarrollado para llevar a cabo los experimentos numéricos descritos, estructurado y documentado para garantizar la reproducibilidad integral de los resultados.

```python
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D

# Generación de Datos

np.random.seed(42) # Para reproducibilidad de los experimentos

# Crear 100 puntos aleatorios en el plano [-2, 2] x [-2, 2]
N_puntos = 100
X_train = np.random.uniform(-2, 2, size=(N_puntos, 2))
x_train = X_train[:, 0]
y_train = X_train[:, 1]

# Función no lineal: z = sin(x)*cos(y) + ruido gaussiano
ruido = np.random.normal(0, 0.05, N_puntos) # Ruido pequeño
z_train = np.sin(x_train) * np.cos(y_train) + ruido


# Implementación del Modelo RBF

def kernel_gaussiano(r, epsilon):
    """Evalúa el núcleo gaussiano dado un radio r y un parámetro de forma epsilon."""
    return np.exp(-(epsilon * r)**2)

def entrenar_rbf(X, z, epsilon, lambda_reg=1e-6):
    """Construye la matriz Phi y resuelve el sistema regularizado para obtener los
    pesos w."""
    n = X.shape[0]
    Phi = np.zeros((n, n))

    # Construcción de la matriz Phi calculando distancias euclídeas
    for i in range(n):
        for j in range(n):
            dist = np.linalg.norm(X[i] - X[j])
            Phi[i, j] = kernel_gaussiano(dist, epsilon)

    # Regularización de Tikhonov: (Phi + lambda * I) * w = z
```

```
    I = np.eye(n)
    w = np.linalg.solve(Phi + lambda_reg * I, z)
    return w

def predecir_rbf(X_train, w, X_test, epsilon):
    """Evalúa el modelo RBF en nuevos puntos X_test."""
    n_train = X_train.shape[0]
    n_test = X_test.shape[0]
    Phi_test = np.zeros((n_test, n_train))

    for i in range(n_test):
        for j in range(n_train):
            dist = np.linalg.norm(X_test[i] - X_train[j])
            Phi_test[i, j] = kernel_gaussiano(dist, epsilon)

    return Phi_test.dot(w)


# Visualización y Estudio de epsilon

# Malla fina de 50x50 para la predicción
x_grid = np.linspace(-2, 2, 50)
y_grid = np.linspace(-2, 2, 50)
X_test_x, X_test_y = np.meshgrid(x_grid, y_grid)
X_test_flat = np.c_[X_test_x.ravel(), X_test_y.ravel()]

# Parámetros a estudiar
epsilons = [0.2, 1.5, 10.0]  # Pequeño, óptimo, grande
lambda_reg = 1e-6 # Penalización para suavizar la superficie

fig = plt.figure(figsize=(18, 5))

for idx, eps in enumerate(epsilons):
    # Entrenar y predecir
    w = entrenar_rbf(X_train, z_train, eps, lambda_reg)
    z_pred_flat = predecir_rbf(X_train, w, X_test_flat, eps)
    Z_pred = z_pred_flat.reshape((50, 50))

    # Graficar
    ax = fig.add_subplot(1, 3, idx+1, projection='3d')
    superficie = ax.plot_surface(X_test_x, X_test_y, Z_pred, cmap='viridis', alpha
    =0.8)
    ax.scatter(x_train, y_train, z_train, c='r', marker='o', s=15, label='Datos con
    ruido')

    titulo = 'Pequeño' if idx == 0 else ('Optimo' if idx == 1 else 'Grande')
    # Uso de raw f-string para evitar SyntaxWarning con \epsilon
    ax.set_title(rf'$\epsilon = {eps}$ ({titulo})')
    ax.set_xlabel('X')
    ax.set_ylabel('Y')
    ax.set_zlabel('Z')

plt.tight_layout()
plt.show()
```

Listing 1: Implementación del Modelo RBF regularizado y visualización de superficies

4 Análisis y Discusión de Resultados

La aplicación del modelo de interpolación mediante Redes de Base Radial (RBF) sobre el conjunto de datos perturbado permitió evaluar empíricamente el compromiso entre la precisión del ajuste local y la capacidad de generalización global, mediado por el hiperparámetro de forma ϵ y la penalización de Tikhonov.

4.1 Análisis Geométrico y Visualización de las Superficies

Al proyectar las predicciones espaciales generadas por el modelo evaluado en los tres regímenes de escala, se evidencian drásticas transiciones topológicas dependientes del parámetro de forma, tal como se observa en las gráficas resultantes:

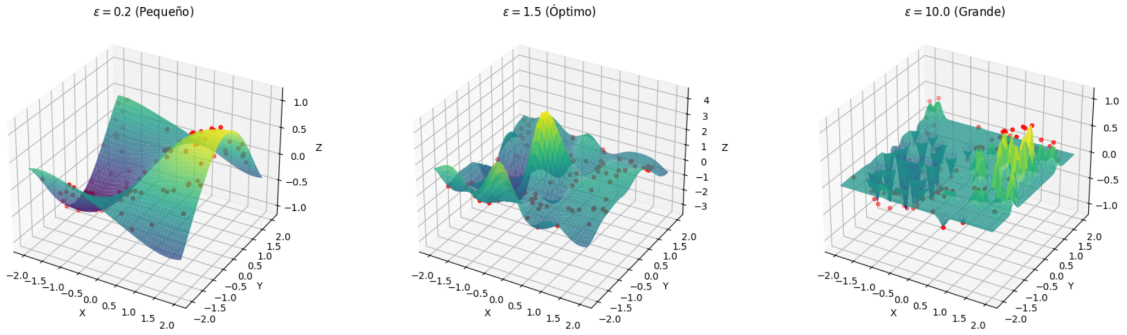


Figure 1: Análisis Geométrico y Visualización de las Superficies

- **Régimen de sobre-suavizado ($\epsilon = 0.2$):** La gráfica izquierda revela una superficie altamente regular y continua, que reproduce de manera estable la topología macroscópica de la función generadora subyacente $\sin(x)\cos(y)$. Al ser ϵ un valor reducido, las funciones gaussianas se ensanchan, otorgando a cada núcleo una extensa área de influencia. En este régimen, el modelo actúa como un filtro de bajas frecuencias espaciales, promediando la varianza inducida por la perturbación gaussiana y priorizando la tendencia determinista del sistema frente al ruido estocástico local.

- **Régimen de sobreajuste o varianza local ($\epsilon = 1.5$):** La proyección central exhibe una superficie con múltiples crestas, valles pronunciados y gradientes abruptos. Con un ϵ de magnitud intermedia, el radio de acción de cada campana gaussiana se circunscribe a un vecindario más restringido. Consecuentemente, el modelo posee suficientes grados de libertad espaciales para forzar la convergencia hacia las anomalías individuales del ruido, sacrificando la suavidad intrínseca de la variedad en favor de un sobreajuste (*overfitting*) a la muestra experimental particular.

- **Régimen de localización extrema ($\epsilon = 10.0$):** La gráfica derecha ilustra el colapso de la capacidad predictiva del modelo en el espacio inter-muestral. Un ϵ elevado genera funciones de base hiper-estrechas, lo que extingue casi instantáneamente la influencia de cada núcleo fuera de su centro respectivo. Topológicamente, esto se traduce en un plano base colapsado en $z \approx 0$ del cual emergen singularidades en forma de espinas agudas exclusivamente en las coordenadas de entrenamiento conocidas, fenómeno clásicamente análogo a una "cama de clavos". El modelo pierde toda capacidad de generalización espacial.

4.2 Rol de la Regularización y Estabilidad Numérica

Un aspecto fundamental evidenciado en los resultados experimentales es la mitigación del mal condicionamiento matricial al acercarse al límite de base ancha ($\epsilon \to 0$). Teóricamente, para $\epsilon = 0.2$, el extremo solapamiento de las bases radiales tendería a generar una matriz de colocación $\mathbf{\Phi}$ cuasi-singular, caracterizada por filas casi idénticas y linealmente dependientes. Sin estabilización matemática, la inversión de esta matriz habría detonado el fenómeno de oscilación numérica, donde los errores de truncamiento inducen pesos $\mathbf{w}$ gigantescos de signos alternantes.

Sin embargo, la incorporación del factor de regularización de Tikhonov ($\lambda = 10^{-6}$) perturbó positivamente el espectro de la matriz del sistema ($\mathbf{\Phi} + \lambda\mathbf{I}$). Esta corrección no solo estabilizó la resolución algebraica, sino que actuó directamente como un mecanismo de contracción (*shrinkage*) sobre el vector de pesos, penalizando magnitudes excesivamente grandes. Esto obligó al algoritmo a ignorar las fluctuaciones ruidosas y priorizar la reconstrucción de una superficie suave que aproxima el fenómeno físico real sin sucumbir a la singularidad numérica del espacio transformado.

5 Conclusiones

El desarrollo de este análisis computacional permitió comprobar la eficacia de las Redes de Funciones de Base Radial (RBF) como una herramienta matemática y algorítmica robusta para la aproximación de superficies continuas a partir de datos dispersos y ruidosos, un desafío recurrente en la modelización de dinámicas complejas y sistemas físicos no lineales. A diferencia de los esquemas de interpolación global polinomial, la superposición de núcleos gaussianos proporciona una flexibilidad topológica superior para reconstruir la variedad subyacente.

A partir de la experimentación numérica realizada, se extraen las siguientes conclusiones fundamentales respecto al comportamiento del modelo:

- **Dependencia crítica de la escala espacial:** El hiperparámetro de forma ϵ define por completo el régimen operativo de la red. Los resultados demostraron que valores reducidos promueven un filtrado eficiente del ruido al integrar información global, mientras que valores excesivamente grandes destruyen la correlación espacial inter-muestral, aislando la predicción en vecindarios hiperlocales y colapsando la capacidad de generalización del modelo.

- **Regularización como estabilizador algebraico:** La matriz de colocación de las RBF es inherentemente susceptible al mal condicionamiento numérico en el límite de bases anchas ($\epsilon \to 0$), lo que induce oscilaciones espurias por errores de truncamiento de punto flotante. La incorporación de la regularización de Tikhonov demostró ser una intervención algorítmica indispensable para amortiguar el sobreajuste y garantizar la invertibilidad del sistema lineal, acotando el crecimiento descontrolado de los coeficientes de ponderación.

- **Filtrado de perturbaciones estocásticas:** Se comprobó que el ajuste óptimo en presencia de ruido no se alcanza mediante la interpolación estricta de las observaciones empíricas. La relajación del sistema mediante la penalización de los pesos $\mathbf{w}$ fuerza a la red a priorizar la suavidad de la función predictora, logrando aislar y descartar la dispersión del ruido de medición para recuperar la señal determinista real.

En síntesis, la conjunción de bases radiales gaussianas con regularización matricial constituye un método de alto rendimiento computacional, brindando la estabilidad numérica necesaria para procesar conjuntos de datos dispersos en entornos de cálculo científico avanzado.