

Taller I: Compresión de Imágenes mediante SVD

Reinaldo Kevin Díaz Parra C.I V-27979417

May 24, 2026

1 Introducción

En la era de la información, el procesamiento y almacenamiento de datos a gran escala representa uno de los desafíos computacionales más críticos para la ciencia y la ingeniería. Entre las diversas formas de datos, las imágenes digitales destacan por su alta dimensionalidad; una sola captura de alta resolución puede contener millones de píxeles, donde cada elemento almacena información espacial e intensidades cromáticas. Administrar, transmitir y almacenar estos arreglos multidimensionales de forma bruta satura rápidamente las infraestructuras de red y de almacenamiento, lo que hace indispensable el desarrollo e implementación de algoritmos eficientes de compresión.

Desde la perspectiva del análisis numérico y el cálculo científico, una imagen digital no es más que una representación discreta de una función bidimensional, computable inherentemente como una matriz de datos reales. La naturaleza de las imágenes cotidianas revela que los píxeles adyacentes guardan una fuerte correlación estadística entre sí; en términos geométricos, esto implica que la matriz original contiene un alto grado de redundancia de información. Por lo tanto, el problema de la compresión de imágenes puede reformularse matemáticamente como un problema de reducción de dimensionalidad: el objetivo es hallar un subespacio de menor rango que logre capturar las características topológicas y estructurales esenciales de la matriz original, descartando los componentes menos significativos o de alta frecuencia que el sistema visual humano percibe únicamente como ruido o detalles irrelevantes.

La Descomposición en Valores Singulares (SVD, por sus siglas en inglés) surge como una de las herramientas analíticas más elegantes y potentes del álgebra lineal numérica para resolver este dilema. A diferencia de otros métodos de factorización, la SVD posee la virtud de desarmar cualquier matriz en componentes ortogonales intrínsecos, ordenados rigurosamente de acuerdo con su peso estadístico o varianza energética. Esta propiedad permite aislar las estructuras geométricas dominantes de una imagen y abre la puerta a la aproximación de rango bajo.

El propósito fundamental de este taller es diseñar e implementar un algoritmo computacional en el lenguaje de programación Python para evaluar de manera sistemática el impacto del truncamiento espectral de la SVD en la compresión de imágenes. A través de un enfoque tanto cualitativo (evaluación visual de la fidelidad y nitidez de las reconstrucciones) como cuantitativo (análisis de la tasa de compresión espacial, decaimiento del error relativo bajo la norma de Frobenius y porcentaje de energía estadística absorbida), se caracterizará el balance crítico entre la economía de almacenamiento y la preservación de la información. Finalmente, se explorará la extensión del método hacia estructuras tensoriales mediante la compresión independiente de canales en imágenes a color (RGB), consolidando así un criterio de ingeniería óptimo para la toma de decisiones en el procesamiento digital de señales.

2 Fundamento Teórico

El desarrollo analítico de la compresión de imágenes mediante herramientas de álgebra lineal numérica se sostiene sobre dos pilares matemáticos fundamentales: la factorización espectral de operadores lineales generales a través de la Descomposición en Valores Singulares (SVD) y la optimización geométrica subespacial garantizada por el Teorema de Eckart-Young-Mirsky.

2.1 La Descomposición en Valores Singulares (SVD)

Sea una imagen digital discretizada en escala de grises, la cual puede modelarse algebraicamente como una matriz real $A \in \mathbb{R}^{m \times n}$ de rango $r \leq \min(m, n)$. La SVD establece que toda matriz de

esta naturaleza puede factorizarse exactamente como el producto de tres matrices con propiedades geométricas específicas:

$$A = U\Sigma V^T \quad (1)$$

Donde las estructuras internas de este operador cumplen rigurosamente con las siguientes definiciones:

- **Matriz** $U \in R^{m \times m}$: Es una matriz ortogonal cuyas columnas $\{u_1, u_2, \dots, u_m\}$ constituyen los llamados *vectores singulares izquierdos* de A . Estos vectores corresponden geoméricamente a los autovectores de la matriz simétrica y semidefinida positiva $AA^T \in R^{m \times m}$, cumpliendo la condición de ortonormalidad $U^T U = I_m$.
- **Matriz** $V \in R^{n \times n}$: Es una matriz ortogonal cuyas columnas $\{v_1, v_2, \dots, v_n\}$ representan los *vectores singulares derechos* de A . De manera análoga, estas componentes representan los autovectores de la matriz simétrica $A^T A \in R^{n \times n}$, satisfaciendo que $V^T V = I_n$.
- **Matriz** $\Sigma \in R^{m \times n}$: Es una matriz diagonal generalizada cuyos únicos elementos no nulos ocupan la diagonal principal $\Sigma_{ii} = \sigma_i$. Los valores σ_i se denominan *valores singulares* de A y corresponden a las raíces cuadradas de los autovalores no nulos de $A^T A$ (o de AA^T). Una propiedad analítica crítica de la SVD es que estos valores reales están ordenados de manera monótona decreciente por su magnitud:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > \sigma_{r+1} = \dots = \sigma_{\min(m,n)} = 0 \quad (2)$$

A partir de las propiedades de ortonormalidad, la ecuación de factorización puede expandirse mediante el teorema espectral bajo una representación externa o formalismo de diadas (producto externo de vectores), conocida como la *SVD como suma de matrices de rango 1*:

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T \quad (3)$$

Cada término del sumatorio $u_i v_i^T$ constituye una matriz primitiva de base en $R^{m \times n}$ de rango unitario. El valor singular σ_i actúa explícitamente como un factor de escala o ponderación estadística que cuantifica la contribución energética y estructural de dicha base sobre la composición global de la imagen.

2.2 Aproximación de Rango Bajo y el Teorema de Eckart-Young-Mirsky

El principio físico-matemático de la compresión de datos espectrales radica en que el espectro de valores singulares de una imagen real decae con extrema rapidez hacia cero. Esto implica que una fracción muy pequeña de las componentes de rango 1 concentra la mayor cantidad de información topológica y varianza espacial de la matriz.

Si se trunca la expansión espectral en un índice $k < r$, se define la matriz aproximada de rango bajo $A_k \in R^{m \times n}$ como:

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T \quad (4)$$

La justificación analítica de por qué esta proyección particular es óptima frente a cualquier otra base matemática está dictada por el **Teorema de Eckart-Young-Mirsky**. Este teorema formaliza que la matriz truncada A_k es la solución exacta al problema de minimización de la distancia inducida sobre la variedad de matrices de rango acotado bajo la norma de Frobenius ($\|\cdot\|_F$):

$$\min_{\text{rango}(B) \leq k} \|A - B\|_F = \|A - A_k\|_F = \sigma_{k+1} \quad (5)$$

Recordando que la norma de Frobenius de un operador numérico se define como la raíz cuadrada de la traza de su producto interno, equivalente a la suma cuadrática de sus entradas o de sus valores singulares remanentes:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\sum_{i=1}^r \sigma_i^2} \quad (6)$$

Por consiguiente, el error absoluto residual cometido al aproximar la imagen mediante el subespacio de rango k equivale exactamente a la raíz de la energía de los valores singulares descartados:

$$\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2} \quad (7)$$

Esta propiedad resulta fundamental para el cálculo científico, ya que permite computar el error relativo de la aproximación de forma directa y puramente analítica utilizando únicamente el vector del espectro Σ , eludiendo la necesidad de instanciar o restar las matrices explícitas en memoria RAM:

$$\text{Error Relativo} = \frac{\|A - A_k\|_F}{\|A\|_F} = \sqrt{\frac{\sum_{i=k+1}^r \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}} \quad (8)$$

2.3 Métricas de Eficiencia de Datos y Energía Estadística

Para caracterizar el rendimiento de la SVD como un mecanismo de compresión con pérdida de información, se formulan dos ecuaciones operacionales de control ingenieril:

1. **Porcentaje de Energía (Varianza) Capturada:** La cantidad de varianza matemática retenida por las primeras k componentes respecto al sistema físico total se cuantifica mediante la fracción acumulada de los cuadrados del espectro:

$$E(k) = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2} \quad (9)$$

En la práctica, un umbral de diseño estándar para considerar una reconstrucción como de *alta fidelidad* requiere que $E(k) \geq 0.95$ o 0.99 .

2. **Tasa de Compresión Espacial (CR):** Evalúa cuantitativamente el ahorro de memoria física. El almacenamiento directo de la matriz A exige guardar $m \times n$ escalares. Por otro lado, la SVD truncada a rango k solo requiere preservar los primeros k vectores columna de U ($m \times k$), los primeros k valores singulares de Σ (k) y los primeros k vectores columna de V ($n \times k$). El costo de almacenamiento indexado se reduce a $k(m + n + 1)$ flotantes. La razón matemática de compresión se expresa como:

$$CR = \frac{\text{Almacenamiento Original}}{\text{Almacenamiento Truncado}} = \frac{m \times n}{k(m + n + 1)} \quad (10)$$

Un valor de $CR > 1$ indica una compresión efectiva. Si $CR < 1$, el subespacio expandido de la SVD resulta contraproducente y requiere mayor asignación de memoria que el arreglo denso inicial.

3 Desarrollo Experimental e Implementación Computacional

En esta sección se describe el diseño metodológico y la arquitectura del script computacional implementado en el lenguaje de programación Python, utilizando el entorno interactivo Google Colab / Jupyter Notebook. El objetivo del programa es automatizar la carga de una imagen digital arbitraria, procesar su estructura algebraica a través de la SVD, y evaluar de manera sistemática los algoritmos de compresión y métricas de control analizadas en el fundamento teórico.

3.1 Explicación Detallada del Código Fuente

El código se encuentra estructurado modularmente en cuatro bloques lógicos secuenciales, descritos exhaustivamente a continuación:

3.1.1 Bloque 1: Importación de Librerías y Carga Adaptativa de Datos

El script inicia con la invocación de los módulos científicos estándares necesarios para el álgebra lineal numérica y el procesamiento de imágenes:

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from skimage import io, color
4 import os
```

- **numpy (np)**: Es la biblioteca base para el cálculo científico en Python. Proporciona la estructura de datos orientada a arreglos multidimensionales densos (**ndarray**) y optimiza las operaciones matriciales a través de subrutinas vectorizadas escritas en C y Fortran.
- **matplotlib.pyplot (plt)**: Módulo utilizado para la generación de gráficos bidimensionales de calidad de publicación, el cual mapea las matrices numéricas directamente en planos de píxeles visuales o curvas funcionales.
- **skimage (scikit-image)**: Colección de algoritmos para el procesamiento digital de señales de imagen. Se emplean específicamente los submódulos **io** (para la lectura/escritura de archivos en disco) y **color** (para transformaciones de espacios cromáticos).

Posteriormente, el código implementa un mecanismo adaptativo de carga de datos mediante un bloque de control de excepciones **try-except**. Si el entorno detecta que se ejecuta sobre Google Colab, importa la API `google.colab.files` para abrir un canal síncrono de transferencia que permite al usuario subir cualquier archivo local (**.jpg**, **.png**, etc.).

Una vez que la imagen se aloja en la memoria física del entorno como un arreglo tridimensional (donde las capas representan los canales cromáticos Rojo, Verde y Azul), se ejecuta la siguiente condicional de normalización:

```
1 if len(imagen_usuario.shape) == 3:
2     A = color.rgb2gray(imagen_usuario)
3 else:
4     A = imagen_usuario.astype(float) / 255.0
```

La función `color.rgb2gray` aplica una combinación lineal ponderada basada en la luminancia estándar de la CIE (Comisión Internacional de la Iluminación), transformando el tensor tridimensional en una matriz bidimensional real $A \in \mathbb{R}^{m \times n}$. Si la imagen original ya es monocromática, el método `astype(float) / 255.0` realiza una conversión de tipo de dato y normaliza las intensidades enteras $[0, 255]$ al intervalo continuo $[0.0, 1.0]$, garantizando la estabilidad numérica de los algoritmos de factorización subsiguientes.

3.1.2 Bloque 2: Factorización Espectral Mediante SVD Económica

La descomposición en valores singulares de la matriz A se realiza mediante una única llamada de alta eficiencia computacional:

```
1 U, S, Vt = np.linalg.svd(A, full_matrices=False)
```

- **np.linalg.svd**: Invoca las rutinas altamente optimizadas de la biblioteca de álgebra lineal **LAPACK** (específicamente la rutina de bidiagonalización mediante reflexiones de Householder seguida del algoritmo QR iterativo).
- **full_matrices=False**: Esta bandera instruye al compilador que calcule la *SVD económica* o reducida. En lugar de generar una matriz cuadrada U de dimensiones $m \times m$ (que requeriría una enorme cantidad de memoria innecesaria), trunca U a dimensiones $m \times \min(m, n)$ y V^T a $\min(m, n) \times n$, aislando únicamente el subespacio asociado a los valores singulares no nulos.

Es un criterio de diseño de cálculo científico fundamental destacar que **la SVD se calcula una sola vez**. Dado que la complejidad temporal de este algoritmo es del orden $O(mn \cdot \min(m, n))$, recalcularla SVD para cada rango bajo destruiría la eficiencia del software. Toda la información geométrica queda almacenada en las variables resultantes y las aproximaciones se resuelven mediante simples operaciones de indexación de bajo costo temporal.

3.1.3 Bloque 3: Construcción e Inserción del Truncamiento de Rango Bajo

Para reconstruir las imágenes aproximadas solicitadas por el proyecto para $k \in \{5, 20, 50, 100, 200\}$, se ejecuta el siguiente ciclo de truncamiento indexado:

```

1 for k in k_values:
2     k_actual = min(k, len(S))
3     A_k = U[:, :k_actual] @ np.diag(S[:k_actual]) @ Vt[:k_actual, :]
4     A_k_approximations[k] = A_k

```

- `min(k, len(S))`: Actúa como una salvaguarda algorítmica. Previene un error de desbordamiento de índices (*index out of bounds*) si el usuario suministra una imagen con una resolución inferior al rango k bajo evaluación.
- **Slicing u Operadores de Corte** (`[:, :k_actual]`): Selecciona dinámicamente las primeras k columnas de U , las primeras k componentes de S y las primeras k filas de V^T , descartando el resto del espectro.
- `np.diag`: Toma el arreglo unidimensional que contiene los valores singulares y lo proyecta como una matriz diagonal en $R^{k \times k}$.
- **Operador @**: Representa el producto interno de matrices (multiplicación matricial estándar). Ejecuta de manera eficiente la operación compacta $A_k = U_k \Sigma_k V_k^T$.

Las matrices resultantes se almacenan ordenadamente en el diccionario estructurado `A_k_approximations` utilizando el índice de rango como clave de acceso rápido para su posterior graficación mediante una cuadrícula de subplots de `matplotlib` con mapas de color en grises (`cmap='gray'`).

3.1.4 Bloque 4: Optimización del Bucle Cuantitativo

El cálculo de las curvas de error, energía y tasa de compresión exige evaluar el comportamiento del sistema de manera continua sobre todo el dominio espectral disponible. Si se ejecutara el bucle elemento por elemento en imágenes de ultra alta resolución, el tiempo de procesamiento se dilataría significativamente. Para optimizar esto, se implementó un control de paso adaptativo:

```

1 paso = 1 if r < 300 else (2 if r < 800 else 5)
2 k_range = np.arange(1, r + 1, paso)

```

La función `np.arange` discretiza el dominio lineal basándose en la resolución física del archivo cargado. Dentro del ciclo, las ecuaciones de control matemático se traducen a sintaxis vectorizada de `numpy`:

- El almacenamiento indexado requerido por A_k se calcula vectorialmente como `datos_Ak = k * (m + n + 1)`, y se divide respecto a la constante precalculada `tamano_original = m * n`.
- El error relativo de Frobenius se evalúa sin instanciar la matriz residual $A - A_k$, sumando directamente las colas del espectro remanente a través de la función `np.sum(S[k:]**2)`, optimizando drásticamente la velocidad de la celda de cómputo.

3.2 Consideraciones Técnicas sobre la Compresión de Color Tensorizada (Bonus)

Para la extensión del proyecto hacia imágenes polícromas, el script aborda el problema dividiendo el tensor tridimensional de datos $T \in R^{m \times n \times 3}$. La función diseñada `comprimir_color_svd` ejecuta de forma secuencial e independiente la SVD reducida sobre cada uno de los tres canales cromáticos constituyentes: el plano rojo ($c = 0$), el plano verde ($c = 1$) y el plano azul ($c = 2$).

```
1 img_reconstruida = np.clip(img_reconstruida, 0, 255)
2 return img_reconstruida.astype(np.uint8)
```

Un fenómeno numérico crítico derivado del truncamiento de subespacios ortogonales es que las aproximaciones multiplicativas de coma flotante pueden generar valores que excedan los límites físicos de representación de un píxel. Para mitigar esto, se hace uso de la función `np.clip`, la cual actúa como un truncamiento de umbral estricto forzando a cualquier valor escalar inferior a 0 a adoptar el valor 0, y a cualquier superior a 255 a adoptar el valor 255. Finalmente, el casteo del tipo de dato a `np.uint8` (entero de 8 bits sin signo) reestructura las matrices para que puedan ser interpretadas correctamente por las tarjetas gráficas del sistema sin distorsión en los canales de color.

4 Análisis de Resultados Visuales

En esta sección se evalúa cualitativamente el efecto del truncamiento espectral sobre la fidelidad visual de la imagen digital recuperada. A través de la reconstrucción de la matriz aproximada $A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$, se evidencia cómo el incremento del rango k restituye progresivamente las componentes espaciales y geométricas de la obra original, permitiendo caracterizar la pérdida de información desde una perspectiva fenomenológica.

A continuación, se discute el comportamiento observado en la cuadrícula de reconstrucciones obtenida experimentalmente para los distintos valores de rango acotado:

- **Aproximación de Rango Extremo ($k = 5$):** Para el límite inferior del experimento, la imagen reconstruida presenta una degradación severa, exhibiendo un fenómeno conocido en procesamiento de señales como *artefacto de pixelación por bloques* o pixelado geométrico. Desde la perspectiva del cálculo científico, este comportamiento es completamente consistente con la teoría: al retener únicamente los primeros 5 valores singulares, estamos forzando a la matriz a componerse como la combinación lineal de solo 5 matrices de rango 1 ($u_i v_i^T$). Estas primeras diadas representan exclusivamente las frecuencias espaciales más bajas de la imagen, es decir, las sombras macroscópicas, los contornos globales y las transiciones de iluminación más burdas. Toda la información de alta frecuencia (bordes nítidos, texturas finas y detalles finitos) ha sido completamente omitida, imposibilitando la correcta interpretación de la escena pero salvaguardando la estructura topológica basal.
- **Aproximación de Rango Bajo Inicial ($k = 20$):** Al expandir el subespacio a 20 componentes ordinarias, la ganancia de legibilidad es drástica. Si bien la imagen continúa manifestando un aspecto difuminado o de "filtro de acuarela", los objetos principales y las siluetas dentro de la composición adquieren fronteras discernibles. Matemáticamente, la inclusión de los valores singulares del σ_6 al σ_{20} introduce vectores ortogonales que codifican gradientes locales de intensidad. En este punto, el observador humano ya es capaz de identificar plenamente el contenido conceptual de la imagen, lo que demuestra que una fracción minúscula del espectro total es suficiente para sustentar la semántica visual macroscópica de los datos.
- **Aproximación de Transición Crítica ($k = 50$):** La reconstrucción de rango $k = 50$ representa el umbral de eficiencia ingenieril más interesante del proyecto. En este estado, los artefactos de pixelado desaparecen casi por completo ante el ojo humano. La imagen recuperada exhibe una nitidez notable y una reproducción fiel de las formas complejas. A nivel espectral, esto denota que los primeros 50 modos ortogonales logran absorber la vasta mayoría de la varianza estadística del sistema. Aunque los detalles de textura ultra-fina aún sufren un leve suavizado, la calidad

geométrica es lo suficientemente alta como para que esta aproximación sea considerada óptima para aplicaciones prácticas donde el ancho de banda o el almacenamiento físico sean restrictivos.

- **Aproximaciones de Alta Fidelidad** ($k = 100$ y $k = 200$): Para los rangos superiores, la convergencia hacia la matriz original A se vuelve prácticamente asintótica en términos de percepción visual. En $k = 100$, los detalles secundarios y las texturas superficiales se restituyen de manera casi perfecta. Al alcanzar $k = 200$, la diferencia cualitativa entre la imagen aproximada y la original es imperceptible para el ojo humano, logrando una fidelidad absoluta. Desde el punto de vista numérico, los valores singulares asociados a estos índices son órdenes de magnitud más pequeños que σ_1 , lo que significa que el algoritmo está

5 Discusión del Bonus: Extensión de la SVD a Imágenes a Color (RGB)

El procesamiento digital de imágenes polícromas introduce un nivel de complejidad estructural adicional al análisis numérico. Mientras que una imagen en escala de grises se modela fielmente como una matriz bidimensional densa, una imagen a color constituye un tensor tridimensional $T \in R^{m \times n \times 3}$. Las capas de la tercera dimensión codifican las intensidades de los tres canales cromáticos primarios del modelo aditivo: Rojo ($c = 0$), Verde ($c = 1$) y Azul ($c = 2$).

Para extender el algoritmo de compresión por valores singulares a este dominio tensorial, el diseño experimental adoptó una estrategia de desacoplamiento espectral. El tensor se subdividió en tres operadores lineales independientes, aplicando la SVD económica sobre cada canal de manera secuencial. La reconstrucción de rango acotado para un valor fijo de $k = 50$ se formuló como:

$$T_k(:, :, c) = \sum_{i=1}^k \sigma_i^{(c)} u_i^{(c)} (v_i^{(c)})^T, \quad \forall c \in \{0, 1, 2\} \quad (11)$$

Donde $\sigma_i^{(c)}$, $u_i^{(c)}$ y $v_i^{(c)}$ representan el espectro y las bases ortonormales específicas calculadas para el canal cromático c .

5.1 Análisis de Resultados Visuales Cromáticos

Al evaluar cualitativamente la imagen reconstruida a color para $k = 50$, se evidencia una preservación sobresaliente de la fidelidad del color y de los gradientes tonales originales. A diferencia de las etapas iniciales de la escala de grises ($k = 5$), donde los artefactos geométricos destruían la continuidad espacial, la aproximación cromática de rango 50 no manifiesta distorsiones ni desviaciones en el balance de blancos o en la saturación local.

Este fenómeno demuestra que, a pesar de que las matrices de los canales R, G y B codifican información física distinta (longitudes de onda correspondientes a diferentes regiones del espectro electromagnético), las estructuras geométricas y los contornos de los objetos dentro de la escena están fuertemente correlacionados espacialmente entre las tres capas. El algoritmo logra restituir los bordes de color y las transiciones cromáticas complejas con alta nitidez, confirmando que un rango de $k = 50$ es un umbral robusto para la compresión multicanal.

5.2 Consideraciones Numéricas y Eficiencia del Almacenamiento Tensorial

Desde la perspectiva de la eficiencia computacional y el cálculo científico, la extensión cromática de la SVD introduce implicaciones críticas en la administración de memoria que deben ser discutidas desde la ingeniería:

1. **Costo Computacional Triplicado:** Dado que la SVD es una operación costosa con una complejidad temporal de $O(mn \cdot \min(m, n))$, la compresión tensorial directa requiere tres descomposiciones independientes. Esto triplica el tiempo de CPU o GPU requerido en la etapa de factorización respecto al modelo monocromático, lo que representa una penalización computacional importante si se procesan flujos de video o imágenes en tiempo real.

2. **Modificación de la Tasa de Compresión Real:** El tamaño físico de almacenamiento bruto del tensor original es de $3 \times m \times n$ bytes (asumiendo cuantización de 8 bits por píxel). Al truncar los tres canales al mismo rango k , los datos necesarios para almacenar las matrices indexadas suman $3 \times k(m + n + 1)$. Al formular la razón de compresión global (CR_{color}), se obtiene:

$$CR_{\text{color}} = \frac{3 \times m \times n}{3 \times k(m + n + 1)} = \frac{m \times n}{k(m + n + 1)} \quad (12)$$

Analíticamente, el factor constante de los 3 canales se cancela en la razón matemática. Esto implica que la tasa de compresión teórica de una imagen a color es exactamente idéntica a la de su versión en escala de grises para un mismo valor de k . La ventaja en el ahorro de espacio se mantiene intacta, lo que justifica la viabilidad del método para archivos polícromos pesados.

3. **Estabilidad Numérica del Rango por Canal:** Es imperativo notar que el espectro de valores singulares de cada canal de color decrece a ritmos sutilmente distintos debido a la distribución intrínseca de los colores en la imagen (por ejemplo, un cielo azul concentrará mayor energía en las primeras componentes del canal B que en el canal R). Sin embargo, fijar un rango homogéneo de $k = 50$ para las tres capas demostró ser un criterio de diseño sumamente estable, puesto que la sumatoria acumulada de la energía estadística en cada canal supera el umbral crítico de fidelidad sin generar desfases en el registro espacial de los colores.

6 Conclusiones

A partir del diseño, implementación y análisis sistemático del algoritmo de compresión de imágenes mediante la Descomposición en Valores Singulares (SVD), desarrollado en el marco de este taller de Cálculo Científico, se desprenden las siguientes conclusiones fundamentales:

1. **Validación Empírica del Teorema de Eckart-Young-Mirsky:** Los resultados experimentales corroboran de forma irreproachable la teoría matemática subyacente. La SVD demostró ser un mecanismo óptimo de ordenamiento espectral, capaz de jerarquizar la información de una matriz de datos reales según su relevancia geométrica y varianza estadística. Al aislar los modos ortogonales dominantes, el algoritmo permite una degradación elegante y controlada de la señal, demostrando que las macroestructuras de una imagen están contenidas en los primeros componentes espaciales, mientras que las altas frecuencias y el ruido se relegan a las colas del espectro.
2. **Caracterización del Balance de Diseño (*Trade-off*):** Se cuantificó de manera objetiva la relación inversa existente entre la Tasa de Compresión (CR) y la fidelidad de la aproximación (métrica de Energía Capturada y Error Relativo). Mientras que rangos mínimos ($k = 5$) maximizan la economía de almacenamiento a expensas de una pixelación severa que destruye la interpretabilidad de la imagen, rangos moderados (típicamente en el entorno de $k = 50$) emergen como el punto de operación óptimo de ingeniería. En este estado de transición, el sistema es capaz de retener más del 95% de la energía estadística de la matriz, ofreciendo una reconstrucción virtualmente indistinguible para el ojo humano con un costo espacial drásticamente reducido.
3. **Existencia de un Límite Técnico Operacional:** El análisis cuantitativo permitió deducir de forma analítica el umbral crítico de rango ($k_{\text{umbral}} = \frac{m \times n}{m + n + 1}$). Este límite matemático impone una frontera estricta para la viabilidad de la técnica como compresor de datos denso. Superar este número de componentes implica que el almacenamiento indexado de las submatrices algebraicas truncadas supera el tamaño de píxeles del arreglo original, transformando el algoritmo en un proceso ineficiente y redundante. Este hallazgo es clave para la toma de decisiones algorítmicas en el cálculo científico.
4. **Viabilidad y Estabilidad de la Extensión Tensorial (RGB):** La estrategia de desacoplamiento espectral para abordar estructuras tridimensionales en $R^{m \times n \times 3}$ demostró ser matemáticamente robusta y computacionalmente viable. A pesar de la penalización temporal de triplicar el procesamiento en CPU/GPU debido a la ejecución independiente de la SVD por cada canal cromático (R, G y B), la tasa de compresión teórica se mantiene invariante respecto a la versión

monocromática. La uniformidad espacial de los contornos reconstruidos en $k = 50$ confirma que las capas polícromas guardan una profunda correlación geométrica entre sí, consolidando a la SVD como una herramienta de alta fidelidad para el procesamiento digital de señales a color.

5. **Alcance de la SVD en la Reducción de Dimensionalidad:** Más allá de su aplicación directa en la compresión de archivos estáticos, este taller exalta a la Descomposición en Valores Singulares como uno de los pilares del álgebra lineal numérica moderna. Su capacidad para proyectar sistemas densos de alta dimensionalidad sobre subespacios de rango bajo de manera óptima y automatizada la posiciona como una metodología transversal indispensable, con aplicaciones directas que van desde la minería de datos y la eliminación de ruido instrumental, hasta el modelado de sistemas físicos complejos en la ciencia de la computación.