

Taller II: Análisis de Componentes Principales (PCA) e Identificación de Ancestría Genética

Reinaldo Kevin Díaz Parra C.I V-27979417

June 14, 2026

1 Introducción

El estudio de la variabilidad genética humana se fundamenta en la identificación de variaciones en la secuencia del ADN conocidas como polimorfismos de nucleótido único (SNPs). Debido a la naturaleza de alta dimensionalidad de los datos genómicos —donde el número de marcadores genéticos suele exceder significativamente el número de individuos analizados—, el Análisis de Componentes Principales (PCA) se posiciona como la herramienta estándar para visualizar la estructura poblacional y detectar procesos de mezcla genética.

Desde una perspectiva de sistemas complejos, la matriz de genotipos puede interpretarse como un sistema dinámico donde los cambios aleatorios se superponen a señales biológicas estructuradas. En este proyecto, se implementa un flujo de cálculo numérico para transformar datos crudos de genotipos en un mapa de ancestría. Para ello, se emplea la Descomposición en Valores Singulares (SVD) sobre una matriz de genotipos normalizada bajo el esquema de Patterson (Wright-Fisher), el cual permite que cada sitio genético contribuya de manera equitativa a la varianza global.

Este enfoque es análogo al análisis de modos de variación en física estadística, donde los autovectores de la matriz de parentesco resultante representan las direcciones dominantes de la señal genética. El objetivo central de este taller es identificar estos modos dominantes, separando la señal biológica de la deriva genética estocástica, y proyectar a los individuos en un espacio de baja dimensión para interpretar su historia de mezcla migratoria.

2 Fundamentos Teóricos

El Análisis de Componentes Principales (PCA) es una técnica fundamental en la reducción de dimensionalidad y el análisis de datos multivariados. En el contexto de la genética de poblaciones, permite proyectar la variabilidad genómica de m polimorfismos (SNPs) en un espacio de baja dimensión, facilitando la visualización de la estructura poblacional y la detección de procesos de mezcla genética.

2.1 La Matriz de Genotipos y Normalización de Patterson

Sea $G \in \mathbb{R}^{n \times m}$ la matriz de genotipos, donde n es el número de individuos y m el número de marcadores genéticos. Cada elemento $G_{i,j} \in \{0, 1, 2\}$ representa el conteo de alelos variantes. Para mitigar el sesgo derivado de la deriva genética y asegurar que cada marcador contribuya equitativamente a la varianza global, se aplica la normalización de Patterson (basada en el modelo de Wright-Fisher):

$$\tilde{G}_{i,j} = \frac{G_{i,j} - 2p_j}{\sqrt{2p_j(1 - p_j)}} \quad (1)$$

donde p_j denota la frecuencia del alelo variante en el SNP j , calculada como $p_j = \frac{\sum_{i=1}^n G_{i,j}}{2n}$.

2.2 Descomposición en Valores Singulares (SVD)

El PCA se implementa mediante la descomposición de la matriz normalizada $\tilde{G}$ utilizando la Descomposición en Valores Singulares (SVD):

$$\tilde{G} = U\Sigma V^T \quad (2)$$

Donde las componentes principales (PC) se obtienen mediante el producto $PC = U\Sigma$. Esta factorización permite descomponer la matriz en:

- U : Matriz ortogonal cuyos vectores columna definen las direcciones de máxima varianza en el espacio de los individuos.
- Σ : Matriz diagonal cuyos valores singulares σ_i cuantifican la magnitud de la varianza capturada por cada modo.
- V^T : Matriz que proyecta la contribución de cada SNP a las componentes principales.

2.3 Perspectiva de Sistemas Complejos

Desde el punto de vista de la física estadística, la matriz de parentesco $K = \frac{1}{m}\tilde{G}\tilde{G}^T$ actúa como una matriz de correlación. Los autovectores de K representan los modos normales de variación del sistema genético. En poblaciones con procesos de mezcla (admixture), los individuos situados entre dos grupos discretos en el espacio (PC_1, PC_2) ilustran una transición genotípica continua. Matemáticamente, el PCA actúa como un filtro que separa la señal biológica estructurada del ruido estocástico derivado de la deriva genética.

3 Desarrollo Experimental

El protocolo experimental para el análisis genómico se estructuró en tres fases consecutivas, orientadas a garantizar la robustez estadística y la estabilidad numérica del algoritmo:

3.1 Filtrado y Control de Calidad de Variantes

Dada la matriz de genotipos crudos $G \in \mathbb{R}^{30 \times 100}$, el primer paso experimental consistió en el cálculo de las frecuencias alélicas de la variante (p_j) para cada uno de los 100 SNPs presentes. Matemáticamente, en un locus bi-alélico dentro de una población diploide, la frecuencia se determina mediante:

$$p_j = \frac{\sum_{i=1}^n G_{i,j}}{2n} \quad (3)$$

Bajo criterios estrictos de control de calidad, se estableció un filtro de exclusión para descartar de manera automática cualquier marcador monomórfico (donde $p_j = 0$ o $p_j = 1$). La eliminación de estas variantes constantes es un paso crítico, dado que carecen de variabilidad informativa y su permanencia provocaría indeterminaciones matemáticas (divisiones por cero) durante la fase de estandarización.

3.2 Estandarización de Patterson

Con el fin de evitar que los marcadores con frecuencias alélicas extremas (muy altas o muy bajas) distorsionaran la estructura de la matriz de covarianza debido a efectos de escala, se procedió a normalizar la matriz de genotipos filtrada. Para cada individuo i y cada SNP j , el genotipo se centró restando su media teórica bajo el equilibrio de Hardy-Weinberg ($2p_j$) y se escaló por su desviación estándar binomial:

$$\tilde{G}_{i,j} = \frac{G_{i,j} - 2p_j}{\sqrt{2p_j(1 - p_j)}} \quad (4)$$

Este procedimiento transforma los datos crudos en variables adimensionales con media aproximadamente cero y varianza unitaria.

3.3 Reducción de Dimensionalidad por SVD

En lugar de computar explícitamente la matriz de parentesco genético $K = \frac{1}{m}\tilde{G}\tilde{G}^T$, la cual es susceptible a la acumulación de errores de redondeo numérico flotante debido al producto de matrices de gran tamaño, se optó por aplicar de forma directa la Descomposición en Valores Singulares (SVD) sobre la matriz normalizada $\tilde{G}$.

El cálculo de la SVD económica ($\tilde{G} = U\Sigma V^T$) extrae los autovectores izquierdos estructurados en U , los cuales corresponden exactamente a las componentes principales del sistema. La proyección final de los individuos en el nuevo espacio bidimensional se ejecutó mediante las dos primeras columnas de la matriz latente de coordenadas:

$$PC = U\Sigma \quad (5)$$

4 Implementación Computacional y Bloques de Código

La arquitectura del algoritmo desarrollado se segmentó en módulos secuenciales interconectados. A continuación, se expone el código fuente implementado en Python, desglosando detalladamente la funcionalidad matemática y computacional de cada instrucción.

4.1 Módulo 1: Importación de Librerías y Carga de Datos

En este bloque inicial se configuran los entornos vectoriales y se realiza la lectura del archivo de genotipos mediante la librería `pandas`.

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4
5 # Lectura indexada de la matriz de genotipos resguardando las etiquetas de las filas
6 df = pd.read_csv('datos_genotipo.csv', index_col=0)
7 G = df.values
8 n, m = G.shape
```

Listing 1: Carga de datos genómicos y desincorporación de metadatos.

Explicación Detallada del Bloque 1:

- `import numpy as np`: Agrega soporte para vectores y matrices multidimensionales, proveyendo funciones matemáticas de alto nivel para operar de forma vectorizada.
- `pd.read_csv(..., index_col=0)`: Carga el archivo estructurado. El argumento `index_col=0` asigna la primera columna de texto (*Individuo_1*, *Individuo_2*, etc.) como los identificadores de fila del índice, impidiendo que los caracteres alfanuméricos interfieran en los cálculos matriciales.
- `G = df.values`: Extrae únicamente la información numérica pura del marco de datos, transformándola en un arreglo bidimensional continuo (`np.ndarray`) de punto flotante de dimensiones $n \times m$.
- `n, m = G.shape`: Recupera las dimensiones de la matriz genómica mediante una tupla, asignando dinámicamente $n = 30$ (individuos) y $m = 100$ (SNPs) para su uso en los denominadores estadísticos subsiguientes.

4.2 Módulo 2: Control de Calidad y Filtrado de Variantes Monomórficas

Este segmento evalúa probabilísticamente las frecuencias de los alelos mutados y aplica máscaras booleanas para purgar el sistema de ruido e indeterminaciones.

```
1 # Estimación de p_j mediante reducción marginal a lo largo del eje de individuos
2 p = np.sum(G, axis=0) / (2 * n)
3
4 # Construcción de la máscara lógica booleana bilateral
5 snps_validos = (p > 0) & (p < 1)
6
```

```

7 # Compresión del espacio muestral basándose en el vector de filtrado
8 G_filtrada = G[:, snps_validos]
9 p_filtrada = p[snps_validos]

```

Listing 2: Cálculo probabilístico de frecuencias y exclusión de polimorfismos constantes.

Explicación Detallada del Bloque 2:

- `np.sum(G, axis=0)`: Suma linealmente los valores de cada columna (SNP). Al especificar `axis=0`, se colapsa el eje de los individuos obteniendo la cantidad de alelos variantes totales en cada locus genético.
- `/ (2 * n)`: Divide la suma por la dotación total de alelos del sistema (los seres humanos son organismos diploides, por ende poseen $2n$ copias). Esto devuelve un vector de frecuencias p_j acotado en el intervalo $[0, 1]$.
- `(p > 0) & (p < 1)`: Genera un vector de compresión booleana (*Boolean Mask*). Evaluará como `True` solo las posiciones donde haya variación genética efectiva y `False` en los marcadores fijos (donde toda la población posee el mismo alelo).
- `G[:, snps_validos]`: Realiza un indexado avanzado sobre la matriz. Remueve físicamente todas las columnas indexadas como `False`, blindando al algoritmo contra indeterminaciones matemáticas futuras y optimizando la carga computacional en memoria.

4.3 Módulo 3: Normalización y Centrado Binomial de Patterson

Se implementa la transformación matemática que contrarresta los efectos de escala geométrica producidos por la deriva genética diferencial de los SNPs.

```

1 # Centrado y escalamiento empleando el principio de Broadcasting de arreglos
2 media_esperada = 2 * p_filtrada
3 desviacion_binomial = np.sqrt(2 * p_filtrada * (1 - p_filtrada))
4
5 G_norm = (G_filtrada - media_esperada) / desviacion_binomial

```

Listing 3: Estandarización y escalamiento bajo el modelo Wright-Fisher.

Explicación Detallada del Bloque 3:

- `media_esperada = 2 * p_filtrada`: Calcula el valor medio esperado para cada genotipo en condiciones de equilibrio genético a partir de las frecuencias remanentes.
- `np.sqrt(2 * p_filtrada * (1 - p_filtrada))`: Computa analíticamente la desviación estándar teórica basada en la distribución binomial de un locus diploide.
- `G_norm = (...) / ...`: Resta a cada fila de la matriz el vector de medias y divide de forma sincrónica cada columna por su respectiva desviación estándar. Este proceso aprovecha el *broadcasting* de `numpy`, ejecutando operaciones matemáticas de alta velocidad a nivel de C interno sin necesidad de estructurar ciclos iterativos pesados (`for`).

4.4 Módulo 4: Factorización SVD y Proyección a Coordenadas de Ancestría

Este bloque realiza el cálculo del álgebra lineal pesada del taller, abstrayendo la matriz latente de distancias poblacionales.

```

1 # Ejecución del resolutor de SVD económica optimizado
2 U, S, Vt = np.linalg.svd(G_norm, full_matrices=False)
3
4 # Proyección matricial al espacio de baja dimensión (PC = U * Sigma)
5 PC = U @ np.diag(S)
6
7 # Aislamiento de las coordenadas cartesianas de los dos modos principales

```

```

8 PC1 = PC[:, 0]
9 PC2 = PC[:, 1]

```

Listing 4: Cómputo de la SVD reducida y mapeo latente de componentes.

Explicación Detallada del Bloque 4:

- `np.linalg.svd(..., full_matrices=False)`: Llama a las subrutinas *Lapack* optimizadas. Al declarar `full_matrices=False` se computa la SVD reducida o económica, limitando las dimensiones de U a 30×30 (espacio compacto de individuos). Esto evita el cálculo redundante de dimensiones nulas de los SNPs, reduciendo la complejidad computacional.
- `np.diag(S)`: El parámetro S es devuelto por Python como un vector ordenado decrecientemente con los valores singulares. Esta función toma ese vector y construye una matriz cuadrada diagonal Σ , necesaria para efectuar el producto matricial.
- $U @ \text{np.diag}(S)$: El operador `@` realiza la multiplicación de matrices pura ($U\Sigma$). El resultado es la matriz PC , donde cada fila representa a un individuo cuyas variaciones genómicas han sido proyectadas en un sistema ortogonal de coordenadas independientes.

4.5 Módulo 5: Renderizado y Guardado Gráfico Vectorial

A partir de las coordenadas extraídas, se genera la visualización cartográfica aplicando el formateo y rotulado científico para la exportación final.

```

1 plt.figure(figsize=(10, 7))
2 plt.scatter(PC1, PC2, c='royalblue', edgecolors='k', s=80, alpha=0.8)
3
4 # Bucle iterativo de mapeo de etiquetas de los individuos
5 for i, txt in enumerate(df.index):
6     label = txt.split('_')[1]
7     plt.annotate(label, (PC1[i] + 0.3, PC2[i] + 0.3), fontsize=9)
8
9 plt.title('Análisis de Componentes Principales (PCA) de Datos Genómicos', fontsize=14)
10 plt.xlabel('Componente Principal 1 ($PC_1$)', fontsize=12)
11 plt.ylabel('Componente Principal 2 ($PC_2$)', fontsize=12)
12 plt.grid(True, linestyle='--', alpha=0.6)
13 plt.savefig('pca_genetica.pdf')
14 plt.show()

```

Listing 5: Graficación y exportación de la dispersión de componentes principales.

Explicación Detallada del Bloque 5:

- `plt.scatter(PC1, PC2, ...)`: Dibuja los puntos en un plano cartesiano bidimensional donde el eje X corresponde al modo de máxima varianza poblacional (PC_1) y el eje Y al modo secundario (PC_2).
- `enumerate(df.index)`: Itera en paralelo sobre las filas devolviendo tanto el contador numérico de posición (i) como el nombre original de la muestra (txt).
- `txt.split('_')[1]`: Segmenta la cadena de caracteres (ej. convierte "Individuo_14" en una lista ["Individuo", "14"]) y extrae únicamente el elemento numérico terminal. Esto remueve texto redundante para mantener el gráfico limpio y legible.
- `plt.savefig('pca_genetica.pdf')`: Exporta la gráfica generada directamente a un archivo PDF. Al ser un formato vectorial, el gráfico se puede ampliar sin perder calidad.

5 Análisis de Resultados y Discusión




Figure 1: Gráfica PC1 vs PC2

La proyección de los genotipos de los 30 individuos en el espacio latente bidimensional definido por las dos primeras componentes principales (PC_1 y PC_2) revela de forma nítida la estructura genética subyacente de la muestra. En lugar de una distribución homogénea o puramente estocástica (ruido gaussiano), el plano cartesiano evidencia una segregación geométrica bien definida que correlaciona directamente con fenómenos de diferenciación poblacional y procesos migratorios de mezcla (*admixture*).

5.1 Identificación de Clusters Poblacionales Puros

El análisis topológico de la gráfica permite identificar, en primera instancia, dos agrupaciones o *clusters* de puntos altamente densos y claramente separados a lo largo del eje del primer componente principal (PC_1):

1. **Cluster Ancestral A (Extremo Derecho - $PC_1 > 0$):** Este grupo concentra a un conjunto compacto de individuos (como los identificados en la periferia derecha). En términos bioinformáticos, este polo geométrico representa a una población de referencia ancestralmente pura. Su homogeneidad en el espacio proyectado indica que comparten frecuencias alélicas idénticas o muy similares en los SNPs que poseen mayor peso matemático (*loadings*) en el autovector V_1 .
2. **Cluster Ancestral B (Extremo Izquierdo - $PC_1 < 0$):** Ubicado en el polo opuesto del eje de máxima varianza, este segundo grupo denota una población de referencia completamente diferenciada de la primera. La distancia euclidiana entre el Cluster A y el Cluster B a lo largo de PC_1 cuantifica la máxima divergencia evolutiva o distancia de fijación genética (F_{ST}) presente en el conjunto de datos.

El hecho de que la separación ocurra principalmente sobre el eje horizontal ratifica que el primer componente principal (PC_1) captura el gradiente macroscópico de ancestría, actuando como el modo normal dominante que absorbe la mayor cantidad de la varianza biológica del sistema genómico.

5.2 Cuantificación del Gradiente de Mezcla Genética (Admixtura)

El hallazgo más relevante desde la perspectiva de los sistemas complejos y la dinámica de poblaciones es la presencia de una serie de individuos distribuidos de forma cuasi-lineal continua a lo largo del espacio intermedio entre ambos polos. Individuos como el **14**, **3**, **26** y **25**, entre otros, no pertenecen a ninguno de los dos núcleos discretos, sino que actúan como un “puente” de transición matemática.

Desde un punto de vista biológico e histórico, este comportamiento es la manifestación exacta de un ****proceso de mezcla genética migratoria****. La posición relativa de un individuo en el intervalo abierto comprendido entre ambos *clusters* es proporcional a sus proporciones de ancestría híbrida:

- Los individuos que se posicionan más cerca del centro geométrico del gráfico poseen una tasa de mezcla cercana al 50% de cada población ancestral, lo cual suele ser indicativo de eventos de hibridación recientes (como individuos F1 o primeras generaciones de mestizaje).
- La dispersión o elongación de estos puntos intermedios a lo largo del eje PC_1 refleja un flujo génico continuo a lo largo del tiempo, donde la recombinación meiótica ha ido fragmentando y distribuyendo los bloques de SNPs de origen ancestral en proporciones variables.

5.3 Interpretación del Segundo Componente Principal (PC_2)

Mientras que PC_1 describe de manera unívoca el eje de mestizaje principal, el segundo componente principal (PC_2 , eje vertical) captura una escala de variabilidad secundaria. La dispersión vertical observada en ciertos individuos (como el esparcimiento hacia los cuadrantes superiores o inferiores) representa variaciones genéticas locales, sub-estratificación dentro de una de las poblaciones o posibles errores estocásticos menores que no alcanzan el orden de magnitud de la señal migratoria principal.

Matemáticamente, la drástica caída en la magnitud de los valores singulares sucesivos en la diagonal de Σ confirma que, tras filtrar las dos primeras dimensiones, el remanente de la matriz normalizada $\tilde{G}$ se comporta como ruido blanco ortogonal, validando la retención exclusiva de este plano bidimensional para la caracterización completa del sistema.

5.4 Cuantificación del Gradiente de Mezcla Genética (Admixtura) y Frecuencias Genotípicas

El hallazgo más relevante desde la perspectiva de los sistemas complejos y la dinámica de poblaciones es la presencia de una serie de individuos distribuidos de forma cuasi-lineal continua a lo largo del espacio intermedio entre ambos polos. Individuos como el **14**, **3**, **26** y **25** no pertenecen a ninguno de los dos núcleos discretos, sino que actúan como un “puente” de transición matemática en el plano del primer componente principal (PC_1).

Desde un punto de vista biológico e histórico, este comportamiento es la manifestación exacta de un proceso de mezcla genética migratoria. La posición relativa de un individuo en el intervalo abierto comprendido entre ambos *clusters* es proporcional a sus coeficientes de ancestría híbrida:

- **Estructura Genotípica de los Extremos:** Matemáticamente, los individuos en los extremos estables poseen un alto grado de homocigosis. El Cluster Ancestral A ($PC_1 > 0$) está caracterizado por una alta frecuencia del genotipo homocigoto para el alelo mutado (valores de 2 en la matriz G), mientras que el Cluster Ancestral B ($PC_1 < 0$) está dominado por el homocigoto de referencia (valores de 0).
- **Heterocigosis en Individuos Mezclados:** Al analizar la matriz de entrada para los sujetos situados en la región central (como el **14** o el **3**), se observa un incremento drástico en la densidad de genotipos heterocigotos (valores de 1). En términos de un modelo de mezcla de dos poblaciones, esto demuestra que dichos individuos heredaron un alelo de origen ancestral A y un alelo de origen ancestral B en una gran proporción de sus loci correlacionados.
- **Dinámica Temporal del Flujo Génico:** La dispersión continua y no agrupada de estos puntos intermedios a lo largo del eje PC_1 refleja que no estamos ante un único evento de hibridación reciente (lo cual agruparía a todos los mestizos exactamente en el centro, representando una generación F1), sino ante un proceso de flujo génico continuo a lo largo del tiempo. Las sucesivas generaciones de recombinación meiótica han fragmentado los bloques cromosómicos ancestrales, distribuyendo las variantes en proporciones continuas a lo largo de la población.

La proyección lineal en PC_1 funciona, por lo tanto, como un estimador continuo del porcentaje de mezcla: un individuo localizado exactamente a mitad de camino entre ambos clusters posee una tasa de ancestría compartida cercana al 50% para cada población originaria, lo que valida el uso de la SVD como un método no supervisado altamente eficiente para reconstruir historias demográficas complejas sin conocimiento previo de las etiquetas poblacionales.

6 Conclusiones

A partir del desarrollo analítico, la implementación computacional y la subsiguiente discusión de los resultados obtenidos en este taller, se desprenden las siguientes conclusiones fundamentales:

1. **Eficacia del PCA en la Reducción de Dimensionalidad Genómica:** El Análisis de Componentes Principales demostró ser una herramienta matemática robusta y altamente eficiente para procesar sistemas de alta dimensionalidad. El algoritmo logró contraer de manera óptima un espacio de características de 100 dimensiones (SNPs) a un plano cartesiano bidimensional (PC_1, PC_2), reteniendo los componentes ortogonales que condensan la mayor fracción de varianza biológica estructurada y descartando con éxito el ruido estocástico derivado de la deriva genética.
2. **Estabilidad Numérica mediante la Descomposición SVD:** La adopción de la Descomposición en Valores Singulares (SVD) en su variante económica (*thin SVD*) sobre la matriz normalizada bajo el esquema de Patterson constituyó una estrategia metodológica superior frente al cálculo clásico de autovalores de la matriz de parentesco K . Este enfoque previno la acumulación de errores de redondeo numérico en punto flotante derivados de productos matriciales extensos, garantizando la estabilidad y convergencia del algoritmo con un costo computacional minimizado.
3. **Caracterización Unívoca de la Estructura Poblacional:** La proyección geométrica discriminó con nitidez la coexistencia de dos núcleos poblacionales ancestrales discretos e internamente homogéneos, segregados a lo largo del eje del primer componente principal (PC_1). Esto ratifica que el modo normal dominante captura el gradiente macroscópico de diferenciación geográfica o evolutiva del sistema genómico estudiado.
4. **Reconstrucción Continua de Procesos de Mezcla (Admixtura):** Se corroboró que el PCA actúa como un estimador continuo no supervisado de la historia demográfica. La presencia de individuos distribuidos de manera cuasi-lineal continua en la región intermodal (tales como las muestras 14, 3, 26 y 25) constituye la evidencia matemática exacta de un proceso histórico de flujo génico y mestizaje migratorio, caracterizado a nivel genotípico por un incremento en la tasa de heterocigosis. La distancia relativa de estos puntos en el plano cartográfico permite inferir sus coeficientes de ancestría híbrida sin necesidad de un etiquetado previo.

En síntesis, el flujo metodológico implementado cumple rigurosamente con los objetivos del taller, demostrando cómo los principios del álgebra lineal numérica y la perspectiva de los sistemas complejos proveen un marco analítico interdisciplinario fundamental para descifrar dinámicas poblacionales a partir de macrodatos biológicos.